

FScout: análise granular de desempenho de atletas de futebol a partir de dados evento a evento

Uma ferramenta de scouting que trata estatística derivada como consulta, e não como coluna.

Gabriel Martins · setembro de 2026 · protótipo funcional já implementado

1. Tema e problema

Ferramentas públicas de estatística de futebol entregam números agregados — total de gols, de passes, percentual de acerto —, granularidade que não sustenta uma pergunta de scouting real, normalmente condicional e combinada: *quantos gols o atleta marcou de perna esquerda, de fora da área, em jogadas iniciadas em escanteio, num recorte de datas e contra certo adversário*. A saída direta, criar uma coluna por estatística, falha por três razões: a lista de combinações é praticamente ilimitada; cada pergunta nova exige alterar o banco e reprocessar tudo; e o número resultante não é auditável.

2. Proposta

Hipótese de projeto: armazenando *o que aconteceu em campo* — uma linha por ação, com seus qualificadores e coordenadas — e calculando *o que se quer saber* no momento da pergunta, uma única base responde tanto às estatísticas previstas quanto às não previstas, de forma rastreável.

O sistema é construído sobre um **modelo de eventos** e um **catálogo declarativo de métricas**. Cada métrica é uma especificação (filtro, agregação, unidade, posições a que se aplica), não um trecho de código isolado. Acrescentar uma estatística é acrescentar uma especificação; e o catálogo, exportado, é a própria tabela de definições operacionais da metodologia.

3. Fontes de dados e integração

Nenhuma fonte aberta atende sozinha ao escopo, o que torna a **integração de fontes** parte do problema de pesquisa, e não um detalhe de engenharia.

FONTE	O QUE FORNECE	LICENÇA / ACESSO
StatsBomb Open Data	Eventos com coordenada, parte do corpo, técnica e xG	Aberta, uso acadêmico
transfermarkt-datasets	Nascimento, altura, pé, valor de mercado, contrato	CC0
Open-Meteo (ERA5)	Clima no horário de cada partida	CC BY 4.0
OpenStreetMap / Wikidata	Coordenadas dos estádios	ODbL / CC0

As fontes não compartilham identificadores. A ligação é feita em três níveis, do sinal mais forte ao mais fraco — escalação da partida com número de camisa, nome dentro do país, nome idêntico e único —, e cada nível **pode recusar** em vez de arriscar. Cada ligação registra o método e a confiança, de modo que todo número exibido é rastreável até a origem.

4. Estrutura do sistema

CAMADA	PAPEL
domínio	Vocabulário e geometria do campo
ingestão	Um adaptador por fonte
ligação	Identidade entre fontes
métricas	Catálogo e motor de avaliação
API	Contrato HTTP

Python 3.13, SQLAlchemy sobre SQLite (schema portátil para PostgreSQL), FastAPI e Dash/Plotly. A dependência entre camadas aponta em uma só direção, e a camada de domínio não depende de banco nem de rede, o que a torna verificável isoladamente.

Qualidade de código verificada de forma automatizada: 160 testes, análise estática e

5. Estado atual: protótipo já em funcionamento

Fundação, ingestão e integração de fontes estão **concluídas e validadas**:

ITEM	SITUAÇÃO
Competições carregadas	Copa do Mundo 2022, Eurocopa 2024, Copa América 2024, La Liga 2020/21
Volume	182 partidas, 662 mil eventos, 1.583 atletas
Ficha biográfica ligada	96,8% dos atletas
Clima por partida	182 de 182

6. Validação

A correção é verificada contra fatos independentes, e não contra a própria implementação:

- **Reconstrução do placar.** Os gols recontados a partir dos eventos conferem com o placar oficial em 182 de 182 partidas.
- **Fatos públicos.** Artilharia e liderança de assistências das competições coincidem com os registros oficiais.
- **Ligação entre fontes.** O método por nome é avaliado contra as ligações obtidas por escalação, que funcionam como gabarito: **98,6% de precisão**. Os casos não resolvidos vão para revisão manual, com o motivo da recusa.
- **Consistência interna.** A minutagem por equipe e partida fica a menos de 3% do esperado para onze atletas em campo.

A validação já revelou defeitos que testes sintéticos não pegariam: escalações com intervalos sobrepostos na fonte, que inflavam minutagem, e um estádio geocodificado no estado errado.

7. Limitações declaradas

- Distância percorrida, sprints e velocidade exigem *tracking data*, inexistente em fonte aberta para essas competições.
- A StatsBomb Open Data não cobre o Campeonato Brasileiro; atletas brasileiros aparecem pela seleção na Copa América 2024.
- A reanálise meteorológica tem grade de cerca de 25 km e suaviza chuva convectiva.

8. Cronograma e situação

ETAPA	SITUAÇÃO
Modelo de eventos, ingestão e integração de fontes	Concluída
Motor declarativo de métricas	Em andamento
API e painel interativo (perfil, comparação, mapas de campo)	Planejada
Consolidação, redação e defesa	Planejada

O que eu gostaria de discutir com o orientador: o recorte final do escopo analítico, o desenho da avaliação — em especial como medir a qualidade da integração entre fontes — e a estrutura do texto do TCC.