

# FScout: os passos da construção, o que já se verifica e o que ficou declarado como limite

Do modelo de dados à interface, com as decisões de método que sustentam cada número.

Gabriel Martins · 16 de setembro de 2026 · protótipo funcional, seis fases concluídas

## 1. O que foi construído

Uma ferramenta de scouting completa, da ingestão à tela: **661.915 eventos** de **182 partidas**, **1.984 atletas**, **108 métricas** em sete famílias, uma API HTTP e um painel com oito visualizações. O código tem **322 testes** automatizados e um registro com 34 decisões de projeto documentadas.

**A decisão que sustenta o trabalho:** estatística derivada é *consulta*, não *coluna*. O banco guarda o que aconteceu em campo — uma linha por ação, com qualificadores e coordenadas — e cada métrica é um filtro declarado sobre isso. "Gol de perna esquerda, de fora da área, em jogada iniciada em escanteio" são quatro condições indexadas sobre a mesma tabela, sem coluna nova e sem reprocessamento.

A consequência prática é que acrescentar uma estatística virou um registro de cinco linhas. O catálogo, exportado, é a tabela de definições operacionais da metodologia.

## 2. Os passos, e o que cada um entregou

| FASE                     | ENTREGA                                                                                                     | EVIDÊNCIA DE QUE FUNCIONA                                                                                                                 |
|--------------------------|-------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------|
| 0. Fundação              | Vocabulário do futebol, geometria do campo, schema de 22 tabelas                                            | 33 testes de geometria aferidos contra medidas oficiais da IFAB (gol de 7,32 m, travessão a 2,44 m, pênalti a 10,97 m)                    |
| 1. Ingestão              | Adaptador StatsBomb evento a evento, com tradução explícita do vocabulário                                  | Placar reconstruído a partir dos eventos confere em 182 de 182 partidas; nenhum valor da fonte ficou fora do vocabulário                  |
| 1b. Combinação de fontes | Ficha do atleta, valor de mercado e contrato (Transfermarkt); estádio geocodificado e clima de cada partida | Ligação de registros com <b>98,6% de precisão</b> (633 de 642), medida contra um gabarito independente; 51 casos recusados e documentados |
| 2. Motor de métricas     | Catálogo declarativo, normalização por 90 minutos, percentil por grupo de posição                           | Artilheiro, líder de assistências e líder de gols evitados da Copa América coincidem com os registros oficiais                            |
| 3. API                   | Contrato HTTP; todo endpoint aceita o mesmo conjunto de recortes                                            | "Gols em junho" e "gols contra determinado adversário" são a mesma chamada com argumentos diferentes                                      |
| 4. Visualização          | Perfil, mapa de chutes, de passes, de calor, boca do gol, radar, tabela comparativa e mapa-múndi            | As 11 finalizações de Lautaro Martínez na Copa América saem no mapa como 5 gols — a artilharia oficial do torneio                         |

### Um princípio de método que atravessa todas as fases

Cada carga foi conferida contra um **fato externo verificável**, e não contra o próprio sistema. Três defeitos só apareceram por causa disso, e nenhum deles teria sido pego por teste sintético: Messi somava 207 minutos numa final de 120 (a escalação da fonte traz intervalos invertidos e sobrepostos); um estádio do Texas foi geocodificado na Virgínia (a busca por nome encontra bairros chamados "Stadium"); e um rodapé anunciava 192 passes progressivos ao lado de um cartão que dizia 108 — nenhum dos dois estava errado, mas um contava tentativas e o outro, acertos.

### 3. De quando são os dados

Esta é uma limitação estrutural do trabalho e precisa estar declarada com números.

| COMPETIÇÃO         | TEMPORADA | PARTIDAS | PERÍODO                 | IDADE    |
|--------------------|-----------|----------|-------------------------|----------|
| La Liga            | 2020/21   | 35       | 27/09/2020 a 16/05/2021 | 64 meses |
| Copa do Mundo FIFA | 2022      | 64       | 20/11 a 18/12/2022      | 45 meses |
| Eurocopa           | 2024      | 51       | 14/06 a 14/07/2024      | 26 meses |
| Copa América       | 2024      | 32       | 21/06 a 15/07/2024      | 26 meses |

O dado de evento mais recente do projeto tem **26 meses**. Os dados biográficos são atuais — os valores de mercado vão até junho de 2026 —, mas o que acontece em campo, não.

O atraso não é escolha do projeto, é a fronteira do dado aberto. O catálogo completo da StatsBomb Open Data tem 80 temporadas, e apenas uma é de 2025 ou posterior (Eurocopa Feminina 2025). No API-Football, o plano gratuito libera 2022 a 2024; temporada corrente exige assinatura paga.

A razão é econômica, não técnica: dado de evento é produzido por pessoas assistindo à partida e marcando cada ação, e é vendido sob contrato. Empresas como a Sofascore *licenciam* esse dado de provedores — não o obtêm de graça. Nenhum trabalho acadêmico sem orçamento reproduz essa cadeia de aquisição.

### 4. A decisão de escopo: duas camadas de dado

Não existe dado de evento aberto para o futebol de clubes sul-americano. Como as 108 métricas são consultas sobre eventos, a cobertura de Brasileirão e Libertadores não pode vir pela mesma via. Para decidir sobre fato, e não sobre impressão, foi escrita uma **sondagem** que mede o que uma fonte de dado agregado entregaria antes de qualquer linha de adaptador ser escrita.

O que ela apurou, gastando sete requisições da cota gratuita:

| MEDIDA                                              | RESULTADO                                                                                   |
|-----------------------------------------------------|---------------------------------------------------------------------------------------------|
| Brasileirão Série A (e Séries B, C e D)             | 2022 a 2024 acessíveis                                                                      |
| Libertadores                                        | 2022 a 2024 acessíveis                                                                      |
| Estatísticas por jogador, por partida               | 33 campos em 11 grupos (finalização, passe, duelo, desarme, drible, falta, cartão, pênalti) |
| Registros de lesão (Brasileirão 2024)               | 1.668                                                                                       |
| Coordenadas, xG, pé utilizado, comprimento de passe | <b>ausentes</b>                                                                             |

A última linha é a mais importante: a camada agregada alimenta *métrica*, mas não alimenta *mapa de campo*. Daí a regra que governa o uso dela em todo o sistema — **as duas camadas nunca se comparam em silêncio**. O percentil passa a particionar por camada, a comparação recusa cruzar métricas que não existem nas duas, e cada número exibe de onde veio. Sem essa regra, um jogador do Brasileirão apareceria num ranking ao lado de um da La Liga com números calculados de formas diferentes — invalidando justamente o que o trabalho defende.

O critério da decisão está escrito em código e coberto por teste, e não depende da leitura de quem olhou a saída. É ele que justifica, no texto final, ter construído ou não essa camada.

### 5. O que foi declarado como limite

- **Distância percorrida, sprints e velocidade** exigem *tracking data*, que não existe para competições com dados de evento abertos.
- **Velocidade de finalização** não é registrada por nenhuma fonte acessível.

- **Salário** não tem fonte aberta confiável; fim de contrato, sim, e está carregado.
- **Erro de escala de ~4%** em distâncias absolutas: a fonte normaliza todo campo para 120×80 jardas. O erro é sistemático e igual para todos, então não afeta comparações entre atletas.
- **O painel sai em modo claro.** Os degraus de cor do modo escuro estão definidos e verificados, mas os controles não são tematizados sem CSS próprio, e meio-tema é pior que nenhum.

Duas dessas limitações não são cortes de prazo: são limites de fonte. Apresentá-las como limitação metodológica declarada, com a medida do erro quando ele existe, é mais defensável que omiti-las.

## 6. Uma nota sobre acessibilidade dos gráficos

---

As cores do painel não foram escolhidas por aparência. O método adotado exige que a segurança para daltonismo seja *calculada*; como a ferramenta de validação original não roda no ambiente de desenvolvimento, ela foi **reimplementada** preservando o modelo de simulação de Machado, Oliveira & Fernandes (2009) e a definição de distância perceptual em OKLab. A reimplementação reproduz exatamente os valores publicados na referência, o que é a prova de que não se desviou dela.

Desse cálculo saiu uma restrição de projeto: em gráficos nos quais qualquer série pode encostar em qualquer outra — dispersão, bolha, radar — o teto é de **três séries**, porque a quarta reprova o piso de distinguibilidade. É por isso que o mapa de chutes tem três classes de desfecho e o radar recusa o quarto atleta, informando o motivo.

## 7. O que falta

---

- **Camada agregada:** carga do Brasileirão em sessões diárias (a cota gratuita permite cerca de um quarto de temporada por dia), conceito de camada no schema, família de métricas própria e a regra de recusa de comparação.
- **Histórico de lesões:** a tabela existe desde a Fase 0, vazia, esperando a fonte.
- **Consolidação:** roteiro de reprodução do clone à primeira tela, testes de ponta a ponta e a redação de metodologia, resultados e limitações.